CLASSIFICATION

Logistic Regression

📌 **التصنيف باستخدام الانحدار اللوجستي (Logistic Regression)**

يُعد **الانحدار اللوجستي** من أشهر نماذج **التصنيف الثنائي (Binary Classification)**، حيث يُستخدم في تحديد احتمالية انتماء عينة معينة إلى فئة محددة. يعتمد هذا النموذج على **دالة لوجستية (Sigmoid Function)** لتحويل المخرجات إلى قيم احتمالية بين 0 و 1، مما يجعله مناسبًا لمهام التصنيف المختلفة.

🔹 **أمثلة على تطبيقاته في مجالات مختلفة، خاصة في علوم البيانات والذكاء الاصطناعي:**

- **التشخيص الطبي:** تصنيف الأورام إلى **حميدة أو خبيثة**.
- **الأمن السيبراني:** تصنيف رسائل البريد الإلكتروني إلى **حقيقية أو سبام**.
- **النماذج المالية:** كشف **الاحتيال المالي** في المعاملات البنكية.
- **التعليم:** قبول أو رفض الطلاب في **الجامعات** بناءً على معايير محددة.
- **رؤية الحاسوب (Computer Vision):** تحديد ما إذا كانت **الصورة تحتوي على كائن معين أو لا**.
- **تحليل المنتجات:** التمييز بين **المنتجات السليمة والتالفة** في خط الإنتاج.

⚡ مميزات الانحدار اللوجستي:

✅ **كفاءة عالية:** سهل التنفيذ والتدريب، ويعمل بكفاءة على البيانات **قليلة الموارد**.

✅ **أقل عرضة لحدوث الانحراف الزائد (Overfitting)** مقارنة بنماذج أكثر تعقيدًا، لكنه قد يعاني في البيانات **عالية الأبعاد**.

✅ **يعمل بشكل جيد مع البيانات القابلة للفصل الخطي (Linearly Separable)**، مما يجعله خيارًا ممتازًا للمهام الأولية في التصنيف.

❌ عيوب الانحدار اللوجستي:

🚫 **غير مناسب للبيانات المعقدة** التي تتطلب فواصل غير خطية بين الفئات، حيث يفترض أن البيانات **تتبع علاقة خطية** مع المتغير المستهدف.

🚫 **يواجه مشكلة عندما يكون عدد الميزات أكبر من عدد الملاحظات**، مما قد يؤدي إلى ضعف التعميم (Generalization).

🚫 **محدود في التعامل مع المشاكل متعددة الفئات (Multi-Class Classification)**، إلا إذا تم توسيعه باستخدام تقنيات مثل **One-vs-All (OvA) أو Softmax Regression**.

📌 💡 **خلاصة:**

يُعد **الانحدار اللوجستي** خيارًا قويًا في التصنيف عندما تكون البيانات **خطية ومنخفضة الأبعاد**، ولكنه قد يفشل في الحالات الأكثر تعقيدًا، حيث تكون النماذج مثل **SVM أو الشبكات العصبية** أكثر كفاءة. لذا، يجب معرفة حدوده واستخدامه في السيناريوهات المناسبة لتحقيق أفضل أداء ممكن. 🚀

1️⃣ **غير مناسب للبيانات المعقدة أو غير الخطية**

- **الانحدار اللوجستي يفترض أن البيانات قابلة للفصل بخط مستقيم** (أو مستوى في الأبعاد الأعلى).
- إذا كانت البيانات **معقدة أو غير خطية**، فلن يتمكن النموذج من التمييز بين الفئات بشكل صحيح، مما يجعله غير فعال.
- الحل في هذه الحالة هو استخدام **نماذج أكثر تعقيدًا**، مثل **SVM مع Kernel Trick أو الشبكات العصبية**.

2️⃣ **يواجه مشكلة عندما يكون عدد الميزات (Features) أكبر من عدد العينات (Samples)**

- في حالة **البيانات الصغيرة** التي تحتوي على **عدد قليل من العينات ولكن بعدد كبير من الميزات**، فإن النموذج قد **يحفظ البيانات بدلًا من تعميمها**، مما يؤدي إلى **ضعف الأداء عند التنبؤ ببيانات جديدة**.
- هذا يُعرف بمشكلة **التعميم (Generalization Issue)**، حيث يصبح النموذج جيدًا جدًا في تذكر البيانات الأصلية لكنه يفشل عند تطبيقه على بيانات جديدة.
- الحل هنا هو **استخدام تقنيات تقليل الأبعاد** مثل **PCA** أو **اختيار الميزات المهمة فقط**.

3️⃣ **غير مناسب لمهام التصنيف متعددة الفئات (Multi-Class Classification) بدون تعديل**

- الانحدار اللوجستي الأساسي يعمل فقط في **التصنيف الثنائي (Binary Classification)**، أي أنه يقرر بين **فئتين فقط (مثلًا: نعم/لا، ناجح/راسب، مصاب/غير مصاب)**.
- عند الحاجة إلى تصنيف أكثر من فئتين، يجب استخدام استراتيجيات مثل:
  - **One-vs-All (OvA)**: حيث يتم تدريب نموذج لكل فئة على حدة ضد باقي الفئات.
  - **Softmax Regression**: وهو امتداد للانحدار اللوجستي يُستخدم لتصنيف عدة فئات مباشرةً.

💡 **الخلاصة:**

- **إذا كانت البيانات غير خطية → لن يعمل بشكل جيد.**
- **إذا كان عدد الميزات كبير مقارنة بعدد العينات → قد يؤدي إلى تعميم ضعيف.**
- **إذا كانت المشكلة بها أكثر من فئتين → يحتاج إلى تعديل ليعمل بكفاءة.**

الدالة اللوغاريتمية

الأس = الناتج Log
الأساس

🔹 ما هو اللوغاريتم؟

اللوغاريتم هو العملية العكسية للأسس.

🔹 **بمعنى آخر:** إذا كان لدينا المعادلة:

$$1000 = {}^{3}10$$

فإن اللوغاريتم العشري يعبر عن الأس بهذه الطريقة:

$$3 = \log_{10} 1000$$

أي أن لوغاريتم العدد 1000 للأساس 10 يساوي 3، لأنه يوجد 3 أصفار أمام الرقم 1.

🔹 القواعد الأساسية للوغاريتمات

✅ **تحويل اللوغاريتم إلى صورة أسية:**

$$A = {}^{C}B \Rightarrow C = \log_B A$$

- مثال:

$$49 = {}^{2}7 \Rightarrow 2 = \log_7 49$$

✅ **الخاصية الأساسية:**

$$0 = \ln 1 \quad ,0 = \log 1$$

- لأن أي عدد مرفوع للقوة صفر يساوي 1.

✅ **لوغاريتم الأساس نفسه:**

$$1 = \ln e \quad ,1 = \log_{10} 10$$

💡 كيف تفيدنا هذه القواعد في الذكاء الاصطناعي وتعلم الآلة؟

📌 **استخدامات اللوغاريتمات في علوم البيانات والذكاء الاصطناعي:**

- تحويل البيانات الأسية إلى نطاق خطي (مثل مقياس Log-Scale في معالجة البيانات).
- حساب الدوال الاحتمالية في نماذج مثل Naïve Bayes.
- قياس معدل التعلم في الشبكات العصبية.
- استخدام دالة Log Softmax في تصنيف البيانات.

أنواع اللوغاريتمات

1 اللوغاريتم العشري (Log)

- أساسه 10.
- شائع في الحسابات اليومية والعلوم والهندسة.
- أمثلة:

$$9 = {}^{9}\log 10 \quad ,5 = \log 100000 \quad ,3 = \log 1000$$

- إذا لم يكن العدد من مضاعفات 10، نحصل على **قيم عشرية**، مثل:

$$3.84 = \log 7000 \quad ,1.69 = \log 50$$

2 اللوغاريتم الطبيعي (Ln)

- أساسه هو الرقم $e \approx 2.718$ وهو ثابت رياضي مهم.
- يستخدم كثيرًا في **الفيزياء، الذكاء الاصطناعي، الشبكات العصبية، ونماذج النمو الأسي.**
- أمثلة:

$$200 = e^{5}.29 \quad ,5.29 = \ln 200 \quad ,1 = \ln e$$

🔷 Sigmoid Function

$$h_\theta(x) = \frac{1}{1 + e^{-\theta^T x}}$$

🔷 How Does It Work?

1️⃣ When x is **large and positive** → $e^{-\theta^T x}$ becomes very small → $h(x)$ **gets close to 1**

2️⃣ When x is **very negative** → $e^{-\theta^T x}$ becomes large → $h(x)$ **gets close to 0**

3️⃣ When $x = 0 \rightarrow h(x) = 0.5$

💡 **In other words:**

- If x is super big (like 1000) → $h(x)$ is almost 1 🔼
- If x is super small (like -1000) → $h(x)$ is almost 0 🔽

📌 الرقم الطبيعي e واللوغاريتم الطبيعي $\ln$

🔹 الرقم الطبيعي e

✅ الرقم e هو ثابت رياضي خاص، **تقريبًا 2.718**، ويستخدم كثيرًا في الحسابات المتعلقة بالنمو الأسي والتغيرات المستمرة.

✅ يمكن تعريفه بهذه الصيغة الرياضية:

$$e = (1 + 1/x)^x$$

✅ عند حسابه باستخدام قيم كبيرة جدًا لـ x، نحصل على:

$$2.718 \approx e$$

📌 **اللوغاريتم الطبيعي $\ln x$ هو لوغاريتم أساسه e** وليس 10 كما في اللوغاريتم العشري العادي، بمعنى أنه يعبر عن القوة التي يجب أن نرفع بها e للحصول على العدد x.

✅ **خصائص مهمة:**

1️⃣ $\ln e = 1 \rightarrow$ لأن $e = e^1$

2️⃣ $\ln 1 = 0 \rightarrow$ لأن $1 = e^0$

3️⃣ $\ln 200 = 5.29 \rightarrow$ لأن $200 \approx e^{5.29}$

📌 الرقم e يظهر في الطبيعة والرياضيات كثيرًا، مثل:

- **نمو السكان أو المال** (الفائدة المركبة المستمرة).
- **الذكاء الاصطناعي** (مثل دالة **Softmax** في تصنيف البيانات).
- **حساب الاحتمالات في تعلم الآلة** (مثل توزيع **Poisson** و**Gaussian**).

💡 ببساطة، اللوغاريتم الطبيعي يُستخدم عندما يكون النمو أو التغير مستمرًا وليس متقطعًا، وله تطبيقات قوية في التحليل الرياضي والعلوم.

1 إذا كان x عدد كبير جدًا (مثل 1000)

- عندها $-x$ سيكون عددًا سالبًا جدًا، مما يجعل e^{-x} **عددًا صغيرًا جدًا يقترب من الصفر.**
- بالتالي تصبح المعادلة:

$$1 = \frac{1}{0+1} = h(x)$$

✅ **النتيجة:** عندما يكون x **كبيرًا جدًا، يكون الإخراج قريبًا من 1.**

2 إذا كان x عدد سالب جدًا (مثل -1000)

- عندها $-x$ سيكون موجبًا جدًا، مما يجعل e^{-x} **عددًا كبيرًا جدًا.**
- بالتالي تصبح المعادلة:

$$0 \approx \frac{1}{\text{عدد ضخم جدًا} + 1} = h(x)$$

✅ **النتيجة:** عندما يكون x **صغيرًا جدًا (سالبًا جدًا)، يكون الإخراج قريبًا من 0.**

3 إذا كان $x = 0$

- عندما يكون $x = 0$، فإن $e^{-x} = e^{0} = 1$.
- بالتالي تصبح المعادلة:

$$0.5 = \frac{1}{2} = \frac{1}{1+1} = h(0)$$

✅ **النتيجة:** عندما يكون $x = 0$، يكون الإخراج **0.5.**

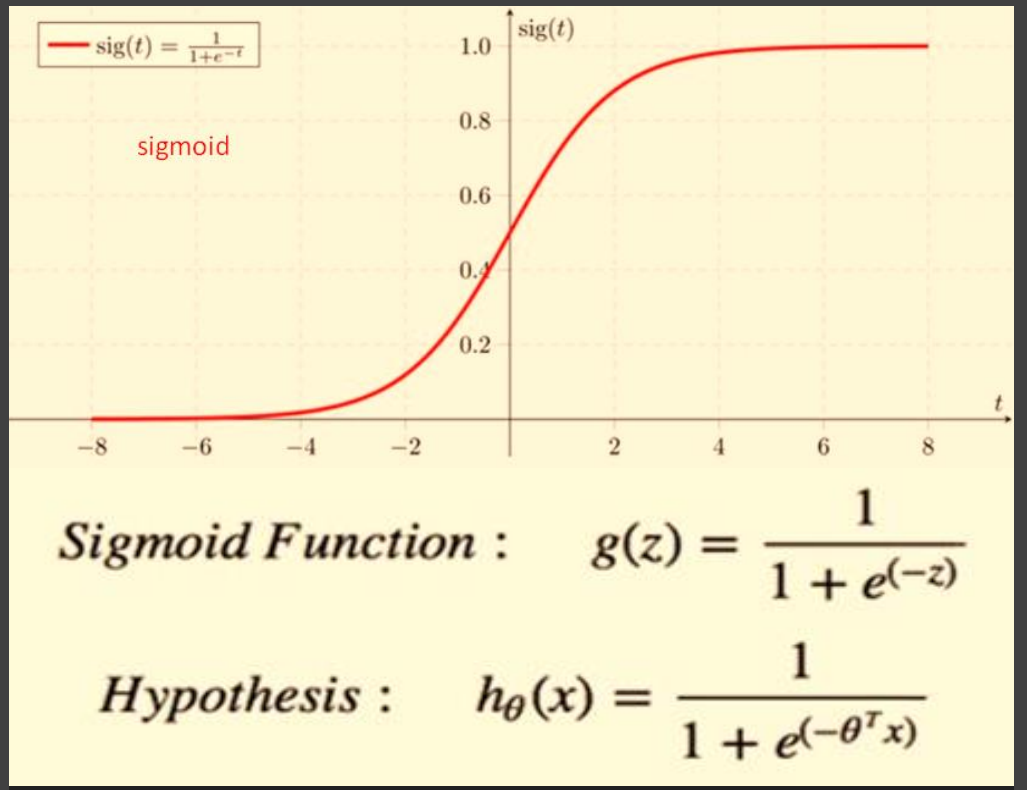

$$\textit{Sigmoid Function}: \quad g(z) = \frac{1}{1+e^{(-z)}}$$

$$\textit{Hypothesis}: \quad h_\theta(x) = \frac{1}{1+e^{(-\theta^T x)}}$$

1. نقوم أولاً بحساب $\theta^T x$ كما في الانحدار الخطي.
2. نطبق دالة **سيجمويد** لتحويل القيم إلى نطاق **بين 0 و 1.**
3. نستخدم حدًا **(0.5 غالبًا)** لتحديد الفئة النهائية.

📌 شرح دالة التكلفة في الانحدار اللوجستي (Cost Function)

🛠️ لماذا نحتاج إلى دالة تكلفة خاصة؟

في الانحدار الخطي، نستخدم خطأ التربيع المتوسط (MSE)، لكن في الانحدار اللوجستي لا يصلح ذلك لأن دالة سيجمويد (Sigmoid) تجعل الدالة غير خطية، مما يؤدي إلى مشاكل في التقارب أثناء التدريب. لذا نستخدم دالة فقدان اللوغاريتم (Log Loss Function).

$$Cost(h_\theta(x), y) = -y\ log(h_\theta(x)) - (1-y) log(1-h_\theta(x))$$

$$Cost(h_\theta(x), y) = \begin{cases} -\log(h_\theta(x)) & \text{if } y = 1 \\ -\log(1-h_\theta(x)) & \text{if } y = 0 \end{cases}$$

🎯 أيهما نستخدم؟

- للتوضيح النظري: الصيغة الثانية أفضل، لأنها تشرح كيف تعمل الدالة عند كل قيمة y.
- للتطبيق البرمجي (مثل PyTorch أو NumPy): الصيغة الأولى أكثر كفاءة، لأنها تتطلب عمليات حسابية أقل عند تنفيذها في كود.

🔹 إذا كان الهدف $y = 1$:

- إذا كانت التوقعات صحيحة ($h(x) \approx 1$) → التكلفة قريبة من 0.
- إذا كانت التوقعات خاطئة ($h(x) \approx 0$) → التكلفة تصبح كبيرة جدًا.

🔹 إذا كان الهدف $y = 0$:

- إذا كانت التوقعات صحيحة ($h(x) \approx 0$) → التكلفة قريبة من 0.
- إذا كانت التوقعات خاطئة ($h(x) \approx 1$) → التكلفة تصبح كبيرة جدًا.

🎯 ماذا تعني هذه الدالة؟

- إذا كان الهدف $y = 1$ → نحاول جعل $h(x)$ قريبًا من 1 حتى تصبح التكلفة صغيرة.
- إذا كان الهدف $y = 0$ → نحاول جعل $h(x)$ قريبًا من 0 حتى تصبح التكلفة صغيرة.
- كلما زادت الأخطاء، زادت العقوبة (Cost) لتصحيح النموذج أثناء التدريب.

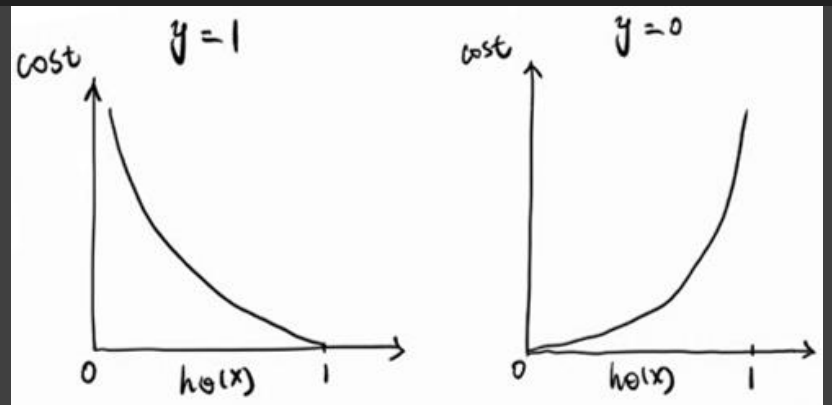

To evaluate the model across all m training examples, we average the cost:

لتقييم النموذج عبر جميع m أمثلة التدريب، نقوم بحساب متوسط التكلفة:

$$J(\theta) = \frac{1}{m} \sum_{i=1}^{m} Cost(h_\theta(x^{(i)}), y^{(i)})$$

Substituting the cost formula, we get:

باستبدال صيغة التكلفة ، نحصل على:

$$J(\theta) = -\frac{1}{m} \left(\sum_{i=1}^{m} y^{(i)} \log(h_\theta(x^{(i)})) + (1-y^{(i)}) \log(1-h_\theta(x^{(i)})) \right)$$

if y = 1 if y = 0

Optimization Function

🔹 1. Finding Beta (θ)

In logistic regression, **θ (theta) represents the model parameters**, which are updated iteratively to find the best-fitting curve for the given data.

The **Gradient Descent update rule** for θ is:

$$\theta_j = \theta_j - \alpha \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)} \right) x_j^{(i)}$$

📌 **Breaking it down:**

- α **(alpha):** The **learning rate**, which controls how much we adjust θ in each step.
- $h_\theta(x)$**:** The predicted output (sigmoid function result).
- y**:** The actual label (1 for positive, 0 for negative).
- x_j**:** The input features.

🔹 2. Representing the Equation as Matrices

Since we often deal with **large datasets**, it's more efficient to express the calculations in **matrix form**:

$$\theta = \theta - \frac{\alpha}{m} X^T \left(g(X\theta) - \vec{y} \right)$$

📌 **Understanding the components:**

- X**:** The feature matrix (**m × (n+1)**) → includes all input data.
- θ**:** The parameters to be optimized (**(n+1) × 1**).
- $g(X\theta)$**:** The sigmoid function output (probabilities between 0 and 1).
- y**:** The true labels (**m × 1**).
- X^T**:** The transposed version of X (used for matrix multiplication).

الاسم	الوزن	السن	فقر الدم	مريض
أحمد	70	18	1	1
حامد	88	22	0	1
منى	91	38	0	1
سيد	65	21	1	0
لبنى	79	25	1	0

المصفوفات :

مصفوفة ثيتا 4X1

$$\begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{bmatrix}$$

مصفوفة y 5X1

$$\begin{bmatrix} 1 \\ 1 \\ 1 \\ 0 \\ 0 \end{bmatrix}$$

مصفوفة X 5X4

$$\begin{bmatrix} 1 & 1 & 18 & 70 \\ 1 & 0 & 22 & 88 \\ 1 & 0 & 38 & 91 \\ 1 & 1 & 21 & 65 \\ 1 & 1 & 25 & 79 \end{bmatrix}$$

تدوير مصفوفة X 4X5

$$\begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 0 & 0 & 1 & 1 \\ 18 & 22 & 38 & 21 & 25 \\ 70 & 88 & 91 & 65 & 79 \end{bmatrix}$$

1. Understanding the Data Structure

The table represents **patients' health data**, which includes:

✅ **Features (X):**

- **Bias term (always 1)**
- **Anemia status (1 = Yes, 0 = No)**
- **Age**
- **Weight**

✅ **Target (y):**

- 1 = Sick
- 0 = Healthy

2. Matrix Formulation

To efficiently update θ, we express the equation in matrix form:

$$\theta = \theta - \frac{\alpha}{m} X^T (g(X\theta) - \vec{y})$$

📌 **Breaking it down:**

- X: Feature matrix (size: **5×4**)
- y: Output labels (size: **5×1**)
- θ: Model parameters (size: **4×1**)
- $g(X\theta)$: Sigmoid function output (predictions)

Key Operations:

1. **Matrix Transposition:** Convert X from **5×4** to **4×5**.
2. **Compute Predictions** $g(X\theta)$.
3. **Subtract** y **from predictions** $g(X\theta) - y$.
4. **Multiply** X^T **by the result.**
5. **Scale by** $\frac{\alpha}{m}$ **and update** θ.

3. Step-by-Step Calculation

- **Predictions** $g(X\theta)$ (before applying sigmoid) are shown in blue.
- **Error term** $g(X\theta) - y$ is calculated.
- **Multiply by** X^T **to compute gradient values.**
- **Apply learning rate** $\alpha = 0.1$ and scale the gradient.
- **Update** θ **values accordingly.**

📌 **Final Updated** θ:

$$\begin{bmatrix} -51.2 \\ -27.3 \\ -1341.2 \\ -4173.3 \end{bmatrix}$$

FEATURE	ELEMENT-WISE UPDATE	MATRIX FORM UPDATE
Formula	$\theta_j = \theta_j - \alpha \frac{1}{m} \sum (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}$	$\theta = \theta - \frac{\alpha}{m} X^T (g(X\theta) - y)$
How It Works	Loops through each parameter and data point one by one	Uses matrix operations to update all parameters simultaneously
Speed	Slower for large datasets (requires loops)	Faster and more efficient (uses optimized matrix math)
Ease of Coding	Requires explicit summation and iteration	Simplified with matrix-vector operations
Best For	Small datasets or learning purposes	Large-scale machine learning models
Parallel Processing	Less efficient for modern hardware	Optimized for GPUs/TPUs using libraries like NumPy or PyTorch
Memory Usage	Uses less memory per step but slower overall	Uses more memory but computes much faster

- is **great for understanding the basics** but isn't practical for large datasets.
- Updates each parameter individually

- it's **faster, scalable, and optimized** for modern hardware,
- Updates all parameters at once

Scalability	Efficiency	Speed	Implementation
Not scalable 🚫	Inefficient ❌	Slow ⏳	Element-wise (Loops)
Scalable ✅	Efficient ✅	Fast ⚡	Matrix Form (NumPy)

ADD

```python
import numpy as np

# Sample data
X = np.array([[1, 18, 70], [1, 22, 88], [1, 21, 91], [1, 25, 79]])  # Features (m x n)
y = np.array([1, 0, 1, 0])  # Labels (m x 1)
theta = np.zeros(X.shape[1])  # Initialize parameters (n x 1)
alpha = 0.01  # Learning rate
m = len(y)  # Number of samples
```

```python
# Gradient Descent (Element-wise)
for epoch in range(100):  # 100 iterations
    for j in range(len(theta)):  # Loop over parameters
        gradient = (1/m) * np.sum((X @ theta - y) * X[:, j])
        theta[j] -= alpha * gradient

print("Theta (Element-wise):", theta)
```

```python
# Gradient Descent (Matrix Form)
for epoch in range(100):
    gradient = (1/m) * X.T @ (X @ theta - y)
    theta -= alpha * gradient


print("Theta (Matrix Form):", theta.flatten())
```

Multi Classification

التصنيف المتعدد (Multi-Classification) هو نوع من التعلم الآلي يُستخدم لتصنيف البيانات إلى **ثلاث فئات أو أكثر** بناءً على الميزات (Features). على عكس التصنيف الثنائي (Binary Classification) اللي بيتعامل مع فئتين بس (مثل: 0 أو 1)، التصنيف المتعدد بيحل مشاكل زي:

- تصنيف الصور (مثل: كلب، قط، طائر).
- تحليل النصوص (مثل: إيجابي، سلبي، محايد).
- تشخيص الأمراض (مثل: مرض القلب، السكري، سليم).

أنواع التصنيف المتعدد

1. **One-vs-Rest (OvR):**
   - بيحوّل المشكلة لتصنيف ثنائي لكل فئة (مثل: كلب ضد باقي الفئات، قط ضد باقي الفئات).
   - بسيط وسريع، لكن ممكن ما ينفعش مع بيانات معقدة.
2. **One-vs-One (OvO):**
   - بيبني نموذج لكل زوج فئات (مثل: كلب ضد قط، كلب ضد طائر).
   - دقيق، لكن بيحتاج وقت أكتر لو عدد الفئات كبير.
3. **Multinomial (Softmax Regression):**
   - بيستخدم دالة Softmax مباشرة لتدريب نموذج واحد يتعامل مع كل الفئات.
   - شائع في التعلم العميق زي الشبكات العصبية.

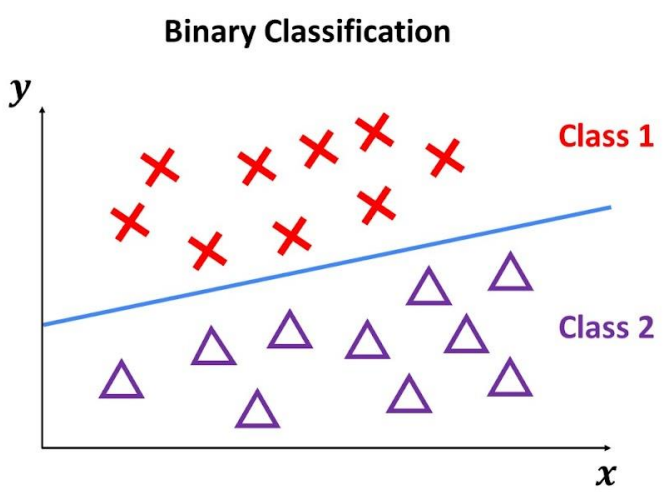

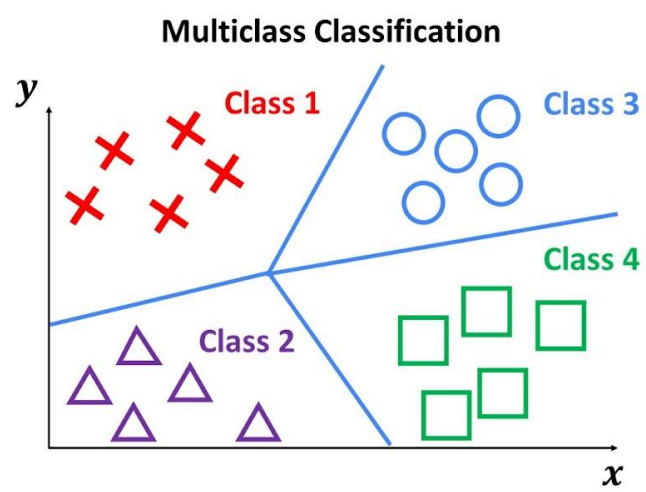

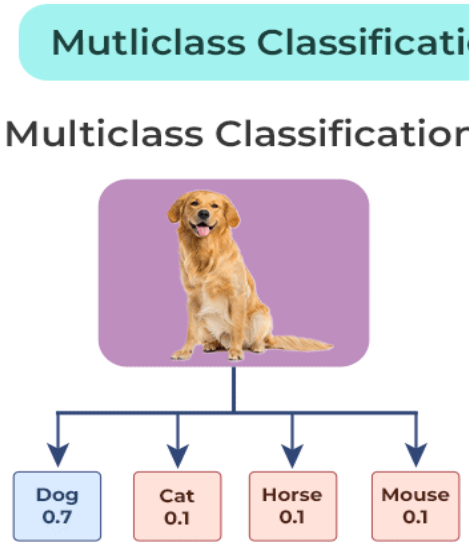

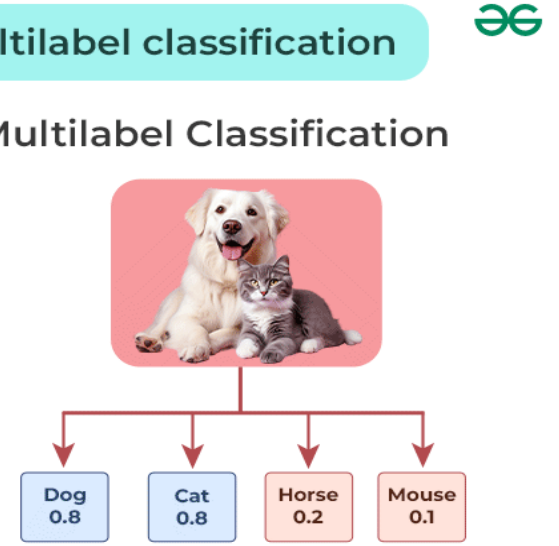

1 One-vs-Rest (OvR) = OvA (One-vs-All)

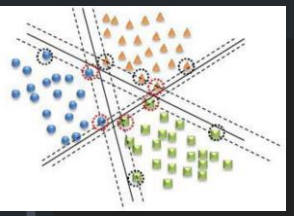

🔹 الفكرة:

- يتم تحويل مشكلة التصنيف المتعدد إلى عدة مشاكل تصنيف ثنائي.
- لكل فئة، يتم تدريب نموذج يميزها عن باقي الفئات.
- مثلاً: يتم تدريب نموذج لتصنيف "كلب ضد باقي الحيوانات"، وآخر لـ "قط ضد باقي الحيوانات"، وهكذا.

🔹 المميزات:

✅ بسيط وسهل التنفيذ، خاصة مع النماذج الخطية مثل الانحدار اللوجستي.

✅ مناسب للمجموعات الصغيرة من البيانات أو عندما يكون هناك عدد قليل من الفئات.

🔹 العيوب:

❌ قد لا يعمل جيدًا إذا كانت الفئات متداخلة بشدة.

❌ غير فعال مع البيانات غير المتوازنة (إذا كانت بعض الفئات نادرة جدًا مقارنة بالبقية).

2 One-vs-One (OvO) = AvA (All-vs-All)

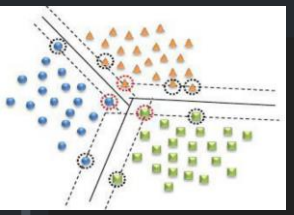

🔹 الفكرة:

- يتم إنشاء نموذج لكل زوج من الفئات الممكنة.
- لكل نموذج، يتم تدريب مصنف يقرر أي الفئتين أقرب لعينة الاختبار.
- إذا كان لديك n فئة، فسيتم تدريب $\frac{n(n-1)}{2}$ نموذجًا.

🔹 المميزات:

✅ دقيق جدًا، لأنه يركز على المقارنة بين كل زوج من الفئات على حدة.

✅ مناسب للمجموعات الصغيرة والمتوسطة الحجم من البيانات.

🔹 العيوب:

❌ عدد النماذج يصبح كبيرًا جدًا مع زيادة عدد الفئات، مما يزيد من زمن التدريب والتعقيد الحسابي.

❌ قد يكون من الصعب دمج النتائج النهائية عند التصنيف.

3 Multinomial (Softmax Regression)

🔹 الفكرة:

- بدلاً من تحويل المشكلة إلى تصنيفات ثنائية، يتم تدريب نموذج واحد يعين احتمالية لكل فئة.
- يستخدم دالة **Softmax** في الطبقة الأخيرة لإنتاج توزيع احتمالي على جميع الفئات.

🔹 المميزات:

✅ بسيط ويعمل بكفاءة، خاصة مع بيانات متوازنة.

✅ مناسب جدًا للتعلم العميق، حيث يستخدم في الشبكات العصبية.

🔹 العيوب:

❌ يفترض أن الفئات غير متداخلة خطيًا، مما قد لا يكون صحيحًا دائمًا.

❌ أقل كفاءة من OvO في بعض الحالات حيث تكون الفئات متقاربة جدًا.

Method 🔹	Best for Small Datasets 📊	Best for Large Datasets 📈	Accuracy 🎯	Complexity ⚡
OvR	Yes ✅	Yes ✅	Medium ⭐	Low 🔽
OvO	Yes ✅	No ❌	High 🌟	High 🔼
Softmax	No ❌	Yes ✅	High 🌟	Medium 🔼

💡 ملخص سريع:

- ✅ **OvR** مناسب للمجموعات الصغيرة بجهد حسابي منخفض.
- 🚀 **OvO** دقيق جدًا ولكنه مكلف حسابيًا.
- 🤖 **Softmax** هو الخيار الأفضل في الشبكات العصبية.

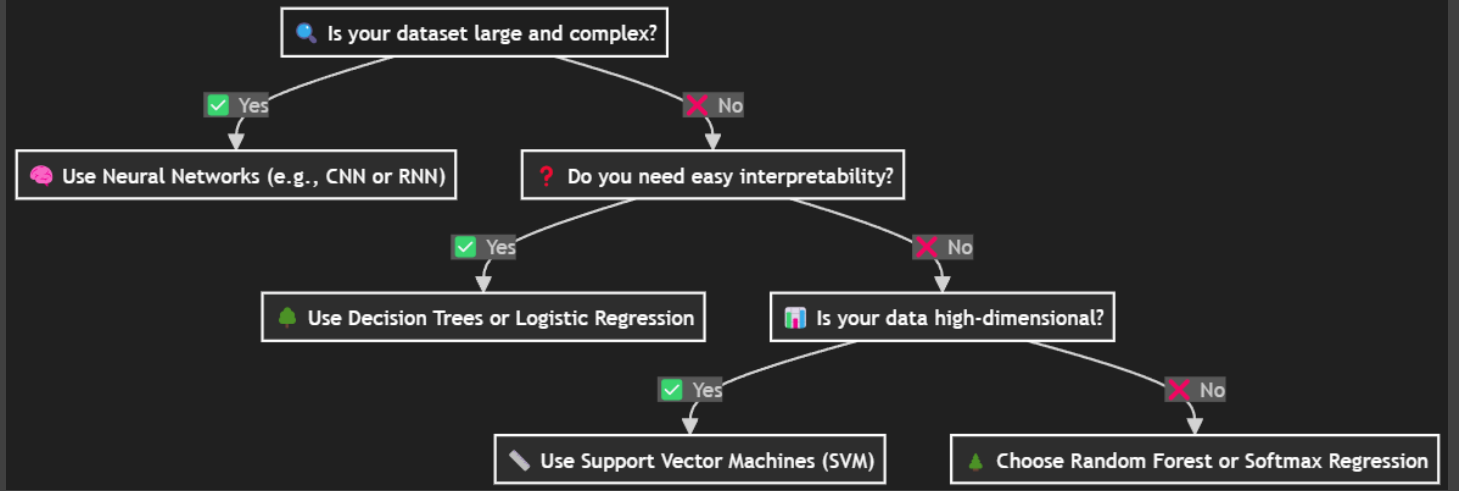

🔹 Comparison of Multi-Class Classification Algorithms

Algorithm	Strengths 💪	Weaknesses ⚠️	Best Use Cases 🎯
Logistic Regression (One-vs-All)	• سهل الفهم وسريع التدريب. • يوفر تفسيرات واضحة للنتائج. • يعتمد على خوارزميات بسيطة.	• غير فعال مع بيانات ضخمة جدًا. • قد يعاني من أداء منخفض مع بيانات غير خطية.	• تصنيف النصوص (مثل تحليل الرسائل). • تحليل بيانات جداول بسيطة.
Softmax Regression	• يعطي احتمالات دقيقة لكل فئة مباشرة. • يدعم نهجًا متعدد الفئات بشكل طبيعي. • مثالي للتكامل مع الشبكات العصبية.	• يعتمد على حدود قرار خطية، مما يحد أداءه مع بيانات معقدة. • قد يحتاج لتعديلات إضافية.	• معالجة اللغة الطبيعية (NLP). • تصنيف الصور الأساسي.
Decision Trees	• سهل التفسير بصريًا (مثل الأشجار). • لا يحتاج تنظيم البيانات مسبقًا. • مرن لتعديل القرارات.	• قابل للإفراط في التكيف (Overfitting). • أداءه يتراجع مع بيانات معقدة جدًا.	• كشف الاحتيال في المعاملات. • تشخيص الأمراض الطبية.
Random Forest	• قوي ومستقر بفضل الأشجار المتعددة. • يتعامل بكفاءة مع البيانات الناقصة. • يقلل من الـ Overfitting.	• بطيء في التوقع إذا كان عدد الأشجار كبيرًا. • يستهلك ذاكرة أكثر.	• تقسيم العملاء في التسويق. • تحليل البيانات البيولوجية.
Support Vector Machines (One-vs-One)	• دقيق جدًا لبيانات صغيرة أو أبعاد عالية. • يعتمد على حدود قرار متميزة (Hyperplanes). • قوي في التفرقة بين الفئات.	• مكلف حسابيًا مع زيادة البيانات. • محتاج تحسينات زي Kernel Trick.	• التعرف على الأرقام اليدوية. • تشخيص طبي دقيق.
Neural Networks (MLP, CNN, RNN)	• يستطيع التعامل مع بيانات معقدة وغير خطية. • قابل للتطوير مع البيانات الكبيرة. • يدعم تقنيات متقدمة (مثل CNN للصور).	• يحتاج بيانات ضخمة وموارد حوسبية عالية. • قد يكون صعب التفسير.	• تطبيقات التعلم العميق. • سيارات ذاتية القيادة وتحليل الفيديو.